En este tutorial, vamos a instalar un cluster de Druid que podrá funcionar en modo multi-nodo. El cluster tendrá las siguientes dependencias:

Deep Storage: S3 AWS

Metadata Storage: PostgreSQL

• Sincronización: ZooKeeper

• Ingesta de eventos desde Kafka.

Instalación ZooKeeper y Kafka

Explicación Kafka

Instalación metadata storage (PostgreSQL)

En primer lugar vamos a instalar PostgreSQL.

Ubuntu/Debian

```
apt-get install -y postgresql
```

OSX

```
brew install postgresql
```

Una vez instalado nos cambiamos al usuario del sistema postgres, para gestionar la base de datos.

```
su postgres
```

Creamos un nuevo usuario en postgresql de nombre druid y le ponemos una contraseña en este caso diurd

```
createuser druid -P
```

Creamos una base de datos de nombre druid que pertenece al usuario que acabamos de crear.

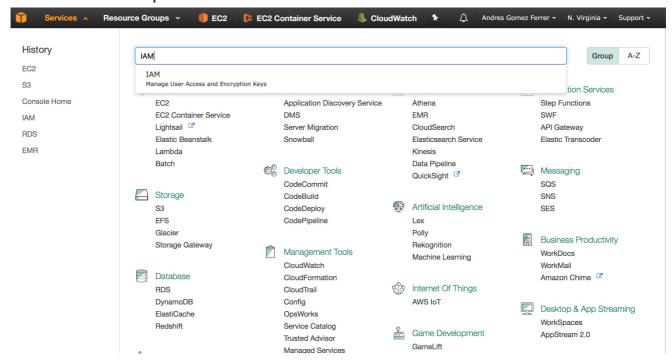
```
createdb druid -0 druid
```

Ya tenemos configurado postgresql y podemos salir del usuario postgres.

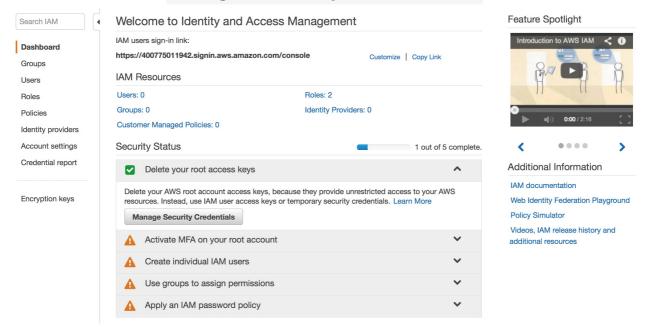
Configuración AWS S3

En primer lugar para poder acceder al servicio desde S3 desde Druid se utilizaran un AccessKey y un SecretKey, entonces vamos a generarlos.

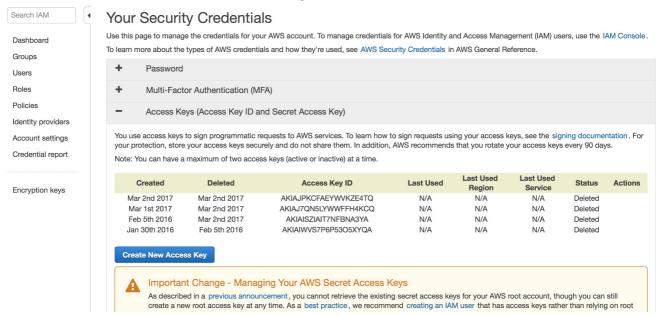
1. Accedemos al panel de IAM.



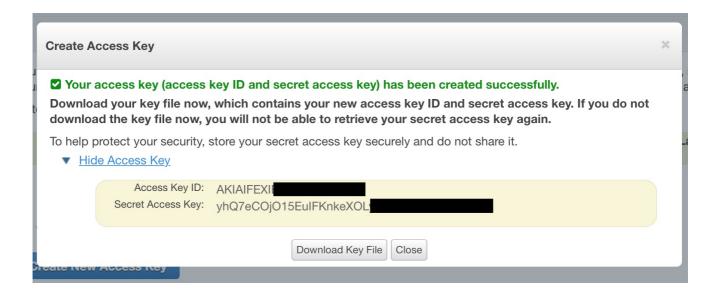
2. Seleccionamos Manage Security Credentials.



3. Creamos una nueva Access Key.

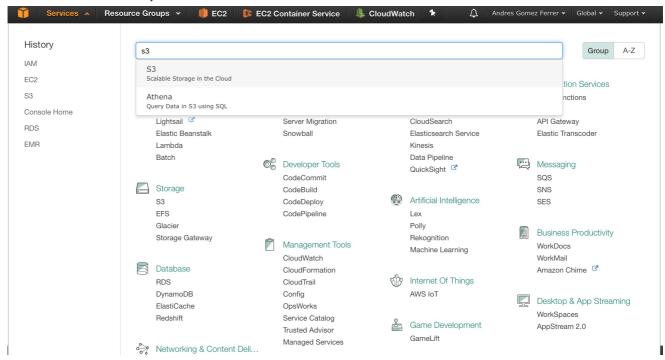


4. Visializamos y descargamos las credenciales. Hay que tener en cuenta que no podremos volver a ver nuestro SecretKey desde la consola de AWS, por lo que hay que guardarla.

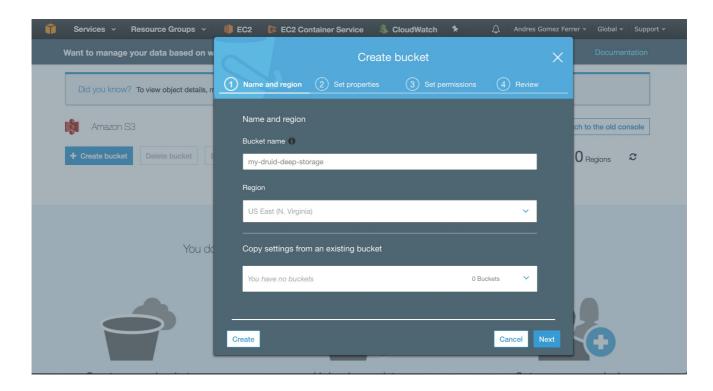


Una vez ya tenemos nuestras credenciales vamos a crear un Bucket de S3, que utilizaremos como Deep Storage.

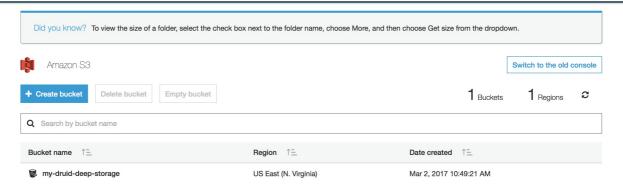
1. Accedemos al panel de S3.



2. Seleccionamos crear Bucket, introducimos el nombre del buckey y nuestra region y seleccionamos siguiente, siguiente, siguiente y crear bucket.



Finalmente podremos ver nuestro Bucket ya creado.



Con esto ya tenemos configurado nuestro Deep Storage para utilizarlo desde Druid.

Instalación Druid

En primer lugar descargamos la última versión estable de Druid y la descomprimimos.

```
wget <a href="http://static.druid.io/artifacts/releases/druid-0.9.2-b">http://static.druid.io/artifacts/releases/druid-0.9.2-b</a>
```

```
tar -xvf druid-0.9.2-bin.tar.gz
```

Una vez ya tenemos la distribución, lo primero que vamos a hacer es configurar Druid para que use nuestro ZooKeeper y nuestro Deep Storage y Metadata Storage. Para ello editamos el fichero:

```
druid-dist/conf/druid/_common/common.runtime.properties
```

1. Cambiamos las extensiones druid.extensions.loadList que utilizaremos en nuestro cluster de Druid. Dejamos las extensiones por defecto, cambiando mysql por postgresql y añadimos la extension de kafka-indexing que usaremos más adelante.

```
druid.extensions.loadList=["druid-kafka-eight", "druid-s
```

2. Configuramos nuestro servidor de ZooKeeper.

```
druid.zk.service.host=localhost:2181
```

3. Comentamos las propiedades de metadata.storage pertenecientes a derby y descomentamos la de postgresql.

Comentamos -->

```
druid.metadata.storage.type=derby
druid.metadata.storage.connector.connectURI=jdbc:derby://
druid.metadata.storage.connector.host=metadata.store.ip
druid.metadata.storage.connector.port=1527
```

Configuramos -->

```
druid.metadata.storage.type=postgresql
  druid.metadata.storage.connector.connectURI=jdbc:postgres
  druid.metadata.storage.connector.user=druid
  druid.metadata.storage.connector.password=diurd
```

4. Ahora vamos a configurar nuestro Deep Storage, para eso comentamos la parte al deep storage local y descomentamos la parte de S3.

Comentamos -->

```
druid.storage.type=local
druid.storage.storageDirectory=var/druid/segments
```

Configuramos -->

```
druid.storage.type=s3
druid.storage.bucket=my-druid-deep-storage
druid.storage.baseKey=druid/segments
druid.s3.accessKey=AKIAIFEXIBU2R7BA----
druid.s3.secretKey=yhQ7eC0j015EuIFKnkeX0Lyf-----
```

5. Configuramos S3 como almacenamiento de los logs de las tareas de indexación:

Comentamos -->

```
#druid.indexer.logs.type=file
#druid.indexer.logs.directory=var/druid/indexing-logs
```

Configuramos -->

```
druid.indexer.logs.type=s3
druid.indexer.logs.s3Bucket=my-druid-deep-storage
druid.indexer.logs.s3Prefix=druid/indexing-logs
```

Una vez configurado el fichero de common.runtime.properties podemos iniciar los servicios y dejar el resto de ficheros con la configuración por defecto.

```
bin/init

bin/coordinator.sh start

bin/broker.sh start

bin/historical.sh start

bin/overlord.sh start

bin/middleManager.sh start
```

Todos los logs se encuentran dentro de la carpeta log, en el inicio de los servicios debemos indentificar esta linea que significa que el servicio ha iniciado correctamente.

2017-03-02T10:53:44,593 INFO [main] org.eclipse.jetty.server

Una vez todos los servicios se han iniciado deberiamos poder ver sus procesos utilizando:

```
root@ip-172-31-59-196:~/druid# ps aux | grep druid | grep ja
        10736 1.7 1.7 8939096 570460 pts/1
root
                                                   10:49
        10905 2.8 2.1 31731828 693608 pts/1 Sl
root
                                                   10:53
        11017 6.3 1.6 13598160 542940 pts/1 Sl
                                                   10:57
root
        11090 11.2 1.7 8924712 573360 pts/1 Sl
root
                                                   10:58
        11197 17.4 0.5 4968964 180244 pts/1
                                              Sl
                                                   10:59
root
```

Ahora que ya que tenemos todo el sistema funcionando, vamos a crear una tarea de indexación que consuma de un topic de kafka llamado metrics y guarde los datos en un dataSource.

Creamos un fichero con este contenido llamado kafka-index.json.

```
{
  "type": "kafka",
  "dataSchema": {
    "dataSource": "metrics-kafka",
    "parser": {
      "type": "string",
      "parseSpec": {
        "format": "json",
        "timestampSpec": {
          "column": "timestamp",
          "format": "ruby"
        },
        "dimensionsSpec": {
          "dimensions": [],
          "dimensionExclusions": [
            "timestamp",
            "value"
```

```
}
    }
  },
  "metricsSpec": [
    {
      "name": "count",
      "type": "count"
    },
    {
      "name": "value_sum",
      "fieldName": "value",
      "type": "doubleSum"
    },
    {
      "name": "value_min",
      "fieldName": "value".
      "type": "doubleMin"
    },
    {
      "name": "value_max",
      "fieldName": "value",
      "type": "doubleMax"
    }
  ],
  "granularitySpec": {
    "type": "uniform",
    "segmentGranularity": "HOUR",
    "queryGranularity": "NONE"
  }
},
"tuningConfig": {
  "type": "kafka",
  "maxRowsPerSegment": 5000000
},
"ioConfig": {
  "topic": "metrics",
  "consumerProperties": {
    "bootstrap.servers": "localhost:9092"
```


```
},
"taskCount": 1,
"replicas": 1,
"taskDuration": "PT1H"
}
```

Para ejecutar la tarea de indexación debemos subir el fichero mediante una peticion POST al Overlord.

```
curl -X POST -H 'Content-Type: application/json' -d @kafka-i
```

Ahora si la tarea se ha levantado podemos verificar que esta funcionando si miramos en la interfaz web del overlod

http://\${OVERLORD_IP}:8090/console.html



Si tenemos la tarea funcionando correctamente podemos enviar datos utilizando el producer de consola de Kafka.

```
root@ip-172-31-59-196:~# date +%s
1488453335

root@ip-172-31-59-196:~# kafka/bin/kafka-console-producer.sh
{"timestamp":1488453335, "value":20.00, "sensor":"ABC"}
```

Finalmente podemos realizar una query a los datos indexados para comprobar su funcionamiento.

Query:

```
"queryType": "topN",
"dataSource": "metrics-kafka",
"granularity": "all",
"dimension": "sensor",
"threshold": 1000,
"metric": "valueSum",
"aggregations": [
  {
    "type": "longSum",
    "name": "count",
    "fieldName": "count"
  },
  {
    "name": "valueSum",
    "fieldName": "value_sum",
    "type": "doubleSum"
```

```
}
],
"intervals": [
   "2017-03-02T11:00:00/2017-03-02T11:30:00"
]
}

curl -sX POST http://${BROKER_IP}:8082/druid/v2/?pretty=true
```


Resultado:

Una vez ya tenemos datos vamos a forzar la creación de un segmento, para ello vamos a apagar la tarea de indexación:


```
curl -X POST -H 'Content-Type: application/json' http://${0V
```

Cuando haya finalizado podemos consultar en la web del Coordinator como ya uno de los historicals tienen segmentos cargados:

http://\${COORDINATOR_IP}:8081/



y podemos veriricar en S3 AWS, que tenemos el segmento y los logs del las tareas de indexación.



Tambien podemos verificar el metadata storage.

1. Cambiamos de usuario a druid.

su druid

2. Accedemos a postgresql.

psql

3. Listamos los segmentos de la tabla correspondiente:

SELECT * FROM druid_segments;